Rating prediction with user business review

一、資料初探：

拿到 training_data.csv，我們做的第一件事，是在未對資料做任何進一步處理的情況下，嘗試使用不同的分類機，大致離不開 Ensenble 與 SVC。對參數做不同的調整，用 score 的高低，初步決定使用 LinearSVC 作為我們的分類機。

二、資料前處理：

在資料的前處理上，我們首先將同時出現在 3 星以下(含)及三星以上的詞彙抓出來，我們希望可以視為雜訊，但卻又發現數量極多，達 18527 筆，且若有只在一部份出現一次、卻在另一部份出現許多次的情況，這樣的處理有失精準。因此我們改用對文字的詞性的處理。

```
------ prefix ------     || ---- possible Adj ----          || ----- verbs ------
DT    a the               || JJ   Adjective                 || VB  Verb, base form
RB   Adverb               || JJR  Adjective, comparative    || VBD Verb, past tense
RBR  Adverb, comparative  || JJS  Adjective, superlative    || VBG Verb, gerund or present participle
RBS  Adverb, superlative  ||                                || VBN Verb, past participle
                          || ---- other ----                || VBP Verb, non-3rd person singular present
                          || UH Interjection                || VBZ Verb, 3rd person singular present
```

對於文字的詞性，用動詞+形容詞的 pattern 來抓取，並且將與 ”not” 相連的形容詞都直接併在一起，避免在學習的時候碰到 good 與 not good 而降低精準度。

此外我們還有嘗試 Textblob 套件中的 correct，試圖想要修正使用者因為輸入錯誤造成的偏誤，但效果並不是很理想，這個套件修正過後的詞彙常常和正確的答案有出入，因此最後也棄掉了。

因為 Textblob 套件中的 correct 效果並不好，我們還突發奇想，想把不屬於 'qazwxdvyhujik' 這些字元的單字，若有重複則去除掉，想要藉此來修正輸入錯誤或誇示的表示法，但效果也非常不好，所以作罷 XD。

三、開始學習：

資料的前處裡大致上到這邊，接著使用 TfidfVectorizer，其中較重要的參數

max_df、min_df 皆設為 1，ngram_range 設為 (1, 1) ，stopword 在嘗試過後決定乾脆不加入，結果較好。

在分類機的選擇上，我們使用了 LinearRegression、LogisticRegression、SVC、RandomForestClassifier 四種 Classifier，並且透過不斷的加權來調整最終的預測結果。

四、最終結果：

透過手動調整與不斷地上傳，我們在 0.65*SVR+0.36*SVC 的時候得到最佳的結果，RMSE 為 0.8282、準確度 0.5047。

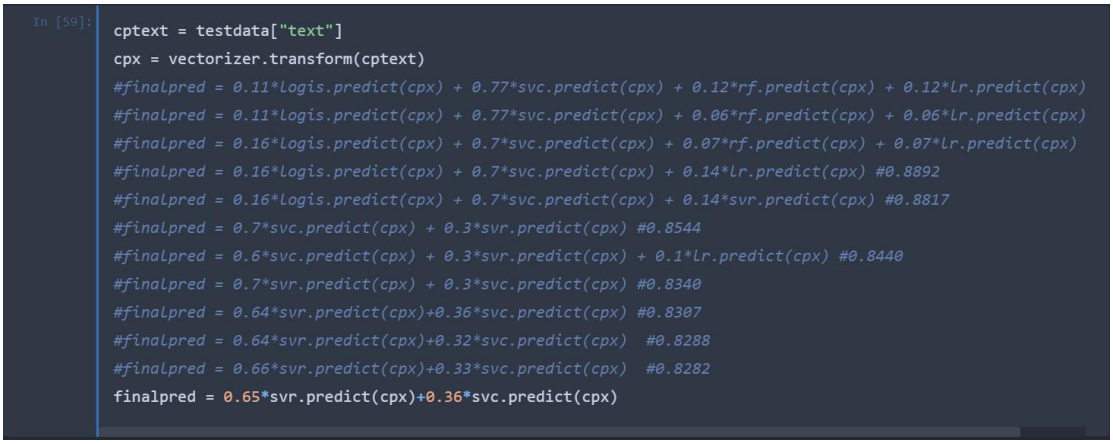

五、Github 連結：

https://github.com/a693691122/cp2